Actividad 6 — Análisis del riesgo de reidentificación

Analizar el resultado obtenido en la actividad anterior.

1. ¿Qué identificadores directos fueron eliminados?

En las consultas de anonimización se dejaron fuera los identificadores directos, como el nombre, el correo electrónico, el teléfono y el RFC. Estos datos no aparecen en los resultados estadísticos, aunque continúan almacenados en la tabla original.

2. ¿Qué cuasi-identificadores permanecen?

Permanecen el rango de edad y la región obtenida de los dos primeros dígitos del código postal. Estos atributos, aunque no identifican directamente a una persona, podrían ayudar a identificarla si se combinan con otros datos disponibles.

3. ¿Qué combinaciones de atributos podrían reducir el anonimato?

La combinación del rango de edad con la región puede reducir el anonimato, especialmente cuando existen pocos registros en un grupo. Si se agregan otros datos, como fechas específicas o información demográfica adicional, el riesgo de reidentificación podría aumentar.

4. ¿Qué sucede cuando un grupo contiene pocos registros?

Cuando un grupo contiene pocos registros, aumenta la posibilidad de identificar a una persona mediante información adicional. Por esta razón, se pueden suprimir los grupos pequeños o generalizar más sus atributos para reducir el riesgo de reidentificación.

5. ¿Qué atributos deberían generalizarse?

Se deberían generalizar las edades en rangos más amplios y los códigos postales en regiones menos específicas. Si fuera necesario, también podrían generalizarse las fechas para evitar que una combinación de datos permita reconocer a una persona.

6. ¿Qué información debería suprimirse?

Se deberían suprimir los identificadores directos, como nombres, correos electrónicos, teléfonos y RFC, de los resultados que se publiquen. También deberían suprimirse o agruparse los resultados estadísticos que correspondan a grupos demasiado pequeños y que representen un riesgo de identificación.

7. ¿Es correcto afirmar que el conjunto de datos es “100 % anónimo”? ¿Por qué?

No es correcto afirmarlo únicamente con las técnicas aplicadas. Aunque las consultas muestran datos agrupados y omiten identificadores directos, todavía pueden existir cuasi-identificadores y combinaciones que permitan inferir la identidad de una persona. Para evaluar la anonimización, es necesario considerar el tamaño de los grupos, la información externa disponible y el contexto en el que se utilizarán o publicarán los resultados.

Reto

Modificar la consulta anterior para reducir aún más el riesgo de reidentificación.

Documentar:

- Cambio realizado: se ampliaron los rangos de edad y se eliminó la región de la agrupación.
- Motivo: reducir la cantidad de detalles que podrían ayudar a distinguir a una persona.
- Resultado obtenido: coloca el resultado real de ejecutar la consulta; no lo inventes.
- Riesgo que se pretende reducir: la identificación de personas mediante combinaciones de edad y región.

```
SELECT
   CASE
      WHEN edad BETWEEN 18 AND 45 THEN '18-45'
      ELSE '46+'
   END AS rango_edad,
   COUNT(*) AS total
FROM public.clientes
GROUP BY 1
HAVING COUNT(*) >= 5;
```

```
n.sql
 rango_edad | total
------------+-------
 31-45      |     4
 46+        |     1
(2 rows)

 region | total
--------+-------
 80     |     3
 81     |     1
 82     |     1
(3 rows)

 rango_edad | region | total
------------+--------+-------
 31-45      | 80     |     3
 31-45      | 81     |     1
 46+        | 82     |     1
(3 rows)

 rango_edad | region | total
------------+--------+-------
(0 rows)

 rango_edad | total
------------+-------
(0 rows)
```