ACTIVIDAD 6. Análisis del riesgo de reidentificación

Objetivo

Analizar el riesgo de reidentificación de los clientes a partir de los datos estadísticos generados en la actividad anterior, identificando los atributos que podrían permitir reconocer a una persona.

1. ¿Qué identificadores directos fueron eliminados?

En las consultas estadísticas se excluyeron los identificadores directos, como el nombre, el correo electrónico, el teléfono y el RFC. También se omitió el identificador individual del cliente. Estos datos no se eliminaron de la tabla original, sino que dejaron de mostrarse en el resultado estadístico.

2. ¿Qué cuasi-identificadores permanecen?

Permanecen el rango de edad y la región obtenida a partir del código postal. Estos atributos no identifican directamente a una persona, pero pueden ayudar a reconocerla cuando se combinan con otra información disponible.

3. ¿Qué combinaciones de atributos podrían reducir el anonimato?

La combinación de edad, código postal, ciudad y fecha de alta puede reducir el anonimato, especialmente cuando existen pocos registros con características similares. Una combinación poco frecuente facilita la identificación indirecta de una persona.

4. ¿Qué sucede cuando un grupo contiene pocos registros?

Cuando un grupo contiene pocos registros, aumenta el riesgo de reidentificación porque sus integrantes pueden distinguirse con mayor facilidad. Por esta razón, se utiliza la cláusula HAVING COUNT(*) >= 5 para mostrar únicamente los grupos que contienen al menos cinco registros.

5. ¿Qué atributos deberían generalizarse?

Se deberían generalizar la edad mediante rangos más amplios y el código postal mediante una región menos específica. También se puede agrupar la fecha de alta por año o excluirla si no es necesaria para el análisis.

6. ¿Qué información debería suprimirse?

Se deberían suprimir los identificadores directos del resultado estadístico, como nombre, correo, teléfono, RFC e identificador del cliente. También deberían omitirse

los grupos que no alcancen el umbral mínimo establecido y los atributos detallados que no sean necesarios para el análisis.

7. ¿Es correcto afirmar que el conjunto de datos es 100 % anónimo? ¿Por qué?

No. Aunque se generalicen algunos atributos y se supriman grupos pequeños, todavía puede existir riesgo de reidentificación mediante la combinación con otras fuentes de información. El umbral de k = 5 reduce ciertos riesgos, pero no garantiza por sí solo el anonimato completo.

Conclusión

La generalización de atributos y la supresión de grupos pequeños ayudan a reducir el riesgo de reidentificación. Sin embargo, es necesario evaluar las combinaciones de cuasi-identificadores y limitar la información publicada para proteger la privacidad de los clientes.

Reto
Utilice rangos de edad más amplios , generalizar la región utilizando solamente el primer digito del código postal y conseravra el umbral de cinco registros.

```
laboratorio1=# SELECT
    CASE
        WHEN edad BETWEEN 18 AND 45 THEN '18-45'
        WHEN edad >= 46 THEN '46+'
        ELSE 'No clasificada'
    END AS rango_edad,
    LEFT(codigo_postal, 1) AS region_general,
    COUNT(*) AS total
FROM clientes
WHERE edad >= 18
  AND codigo_postal IS NOT NULL
GROUP BY 1, 2
HAVING COUNT(*) >= 5;
 rango_edad | region_general | total
------------+----------------+-------
(0 rows)

laboratorio1#
```

Reto: Reducción del riesgo de reidentificación

Cambio realizado: Se ampliaron los rangos de edad, se generalizó el código postal utilizando únicamente su primer dígito y se mantuvo la condición HAVING COUNT(*) >= 5.

Motivo: Reducir la precisión de los cuasi-identificadores y evitar que se publiquen grupos con pocos registros.

Resultado obtenido: La consulta muestra únicamente los grupos que cumplen el mínimo de cinco registros. Si ningún grupo cumple esa condición, no se muestran resultados.

Riesgo que se pretende reducir: La identificación indirecta de clientes mediante combinaciones poco frecuentes de edad y ubicación geográfica.

Limitación: Estas medidas reducen ciertos riesgos, pero no garantizan que los datos sean completamente anónimos.